

9-dars : Auto Pipeline

• ColumnTransformer : **class**

• Barcha transformation avtomatik kechadi:
 ↳ Numeric → missing values, MinMaxScaler, StandardScaler

↳ Categorical → missing values, OneHotEncoder, ~~LabelEncoder~~

↳ Buning o'rniga: Ordinal Encoder

Label Encoder ⇒ Alfbo tartibida o dan boshlab raqamlarni qo'ssa

Ordinal Encoder ⇒ Qandaydir ketma-ketlik bo'lsa qilib ketishi mumkin.

ColumnTransformer = qoidasiga ko'ra eslab qolish k-k: **Label Encoder**ni **o'rniga** **Ordinal Encoder** ishlatish k-k

Har bir numeric yoki categorical qiymatni
 Birinchi Auto Pipeline hosil qilayot kanimizda
 aniqlashtirib olishimiz k-k.

1-Qoida

• Asosiy + :


- ↳ Production-ready (Foydalanishga tayyor)
- ↳ Clean & maintainable (toza va stabil ishlaydi)
- ↳ Automatic handling of new data inputs
(Yangi input datalarni kiritilganda avtomatik handling qiladi) → avtomatik jarayon davom etadi.

• Asosiy componentlar :

↳ Column Transformer → Turli xil ustun/uy birgalikda ketishini ta'minlaydi.

↳ Pipeline — Preprocessing + Algoritmni birlashtiradi.

↳ Bu orqali biz: Automates workflow, reproducible, deployable



Algoritmga qo'shamiz. Va bular birgalikda bitta sistema xosil boladi.

▲ Boshqacha componentlar :

- Ordinal Encoder → Label Encoder sifatida ishlatiladi

↳ handle - unknown :

- Error

- Ignore

- (handle - unknown = 'use_encoded_

value', unknown_value = -1)

↳ ma'lumot beramiz

Agar unseen dataset bo'lsa, oldin ko'rmagan ma'lumotlarimiz bo'lsa, workflowni uzib qo'yamashlik uchun, masalan standart ishlatilayotgan da svt o'chiq bo'lsa ishlaymay qoladi ku. Huddi shuni oldini olish u-n, bir () ichida parametrlar berib ketamiz.

U parametrlardan biri fagat categorical qiymat/ u-n Ordinal Encoding ni berib ketamiz.

(handle - unknown = 'use_encoded_value', unknown_value = -1)

Yani oldin ko'rmagan qiymatni o'ziga -1 qo'yib ketaveradi.

- One-hot Encoder :

↳ handle - unknown = "ignore" => buni qilsak qiymatlarga avtomatik 0 qiymat qo'yib yuboradi.

Bizda biror narsa avtomatlash tiril yaptirni unga o'zshimcha nimadir bilish k-u. Bizda o'zi yotda mansub component.

• Buning + tomonli:

- ↳ Production - ready
- ↳ Clean & maintainable
- ↳ Automatic handling of new data inputs
- ↳ Automation: Users only provide raw data input
- ↳ Preprocessing is automatic
- ↳ Consistency: No risk of forgetting scaling or encoding steps.

Amaliy qismi

```
import pandas as pd
from sklearn.preprocessing import OrdinalEncoder,
MinMaxScaler
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
```

numerical va categorical ustun/ni aniqlash.

```
num_col = df.select_dtypes(include = ['int64', 'float64'])
               .columns.drop('target').tolist()
```

sababi biz keyinchalik for loop, yoki shunga o'xshash ish/ni amalga oshiramizda, yoki jarayon oson bo'lish h-h lekin pandas dan ko'ra best - biz uchun qulay bo'ladi.

Agar tolist() qilmasak → bu pandas typeda turibdi lekin tolist() qilsak → list'ga convert qilib beradi.

↳ shuning uchun doimo list'ga o'tib olishimiz h-h.


```
cat_col = df.select_dtypes(include = ['object']).columns.tolist()
```

```
for col in cat_col:
```

```
df[col] = df[col].astype(str)
```

→ categorical qiymat/ =
haqiqatdan ham string
qiymat ekanligini
oldindan
stringga qilib
qo'yamiz

Preprocessor degan pipeline yaratamiz

```
preprocessor = ColumnTransformer(
```


```
( 'num', MinMaxScaler(), num_col),
```

```
( 'cat', OrdinalEncoder(handle_unknown =  
'use_encoded_value', unknown_value = -1), cat_col)
```

```
)
```

preprocessor

⇒ Buni chaqirsak



⇒ Bunday
korinishda ays
chizma
chizadi.

ML Lifecycle

Umumiy g'oya

Tasavvur qiling, siz TOPIK imtihoniga tayyorlanaysiz

Ma'lumot yig'ish

Tayyorlash

O'qish

Imtihon topshirish

Eng yaxshi natijani taulash

Real hayotda ishlatish

Yangi ma'lumot kelganda yana qayta o'qish.

~~Appdata~~

1. Data (yashil rang)

Rasm = birinchi qismi

App Data → Data Preprocessing →
→ Training & Test Dataset

App Data → Bu siz yig'gan xom ma'lumot
lasalan: Heart disease bo'yidagi

Age

Gender

BP

Cholesterol

Heart Disease

Smoking

...

Bu hali tartibsiz.

Hayotiy misol: Professor sizga
1000 ta talabaniing natijasini
berdi.

Bu hali ishlatishga tayyor emas.

Data Processing

Eng muhim bosqich

Bu yerda:

- Missing values
- Duplicate
- Encoding
- Scaling
- Feature Engineering
- Feature Selection

hammasi bajariladi

Siz = Poyi haqir da masalan:

- Ordinal Encoder
- MinMax Scaler
- Train Test Split

Hammasi Data Preprocessing

Hayotiy analogiya:

Sabzavot sotib oldingiz

lekin ovqat qilishdan oldin

→ yuvasiz, archasiz, maydalaysiz => Shundan keyin ovqat tayyorlaysiz.

Training va Test Dataset
Dataset ikkiga bo'linadi.

80%



Training

20%



Testing

Nega? Chunki modelni keyin tekshirish k-k.
Hayotiy analogiya

1000 ta test savoli bor. 800 tasini o'qidingiz.
200 tasini yashirib qo'ydingiz. Keyin imtihon
sifatida ishlatasiz.

2. Training (~~yashir~~ ^{taizil})

Training Dataset



Model Training



Trained Model

Bei model o'qiyoligan joy

Masalan;

Random Forest

OR

XGBoost

OR

Logistic Regression

Hamma shu yerda

Model pattern topadi

Masalan;

Age > 80

va

BP yuqori bo'lsa

→ Heart Disease ehtimoli katta

Model manashuni o'rganadi

Hayotiy analogiya → Talaba kitob o'qig'chi Reading = Training

3. Validation (Binafsha)

Bu eng ko'p chalkashiradigan gism.

Test Dataset

+

Trained Model

↓

Validation

↓

Best Model

Bu yerda model
sinovdan o'tadi

Masalan:

Accuracy

Precision

Recall

F1

ROC AUC

Hammasi shu yerda hisoblanadi

Hayotiy analogiya →

Talaba imtihon topshirdi.

Natija:

Student A → 95%, Student B → 91%,
Student C → 98%

→ Eng yaxshisini tanlaysiz
ham shunday.

Model :

Random Forest → Accuracy - 95%

XGBoost → Accuracy - 97%

Support Vector Machine → Accuracy - 94%

Eng yaxshisi XGBoost bo'ladi.

→ shu production model bo'ladi.

Model Storage

Best Model



Save

Model

heart_model.pkl yoki heart_model.joblib

Keyin streamlit ishlatadi.

4. Serving (Kö)

Model Production

User



Input



Prediction Service



Prediction

Ma'lumot stream lit

User yozadi:

Age = 65

ISP = 150

Chol = 280

} Prediction service modelni
chag'iradi.

Model aytadi:

Heart Disease → 92% ehtimollik bilan
servis

Hayotiy amaliyot

Talaba endi ishga kiradi. Endi bilimni ish-
latayapti.

Prediction Logging

Har bir prediction yozib boriladi:

Ma'lumot:

Prediction



Time



User



Probability

Saxlanadi. Nega?

Keyin model noto'g'ri ish-
latayotganini aniqlash
U-h.

App Logging

— Bu esa dastur loglari

Masalan:

- Server started
- Error
- Request
- Timeout

} Bular prediction emas
Dastur loglari

Dataset Storage

— Bu yerda barcha ma'lumotl saqlanadi
Masalan:

- Old Dataset
- New Dataset
- Training Dataset
- Test Dataset

} hammasi

Model Storage

— Bu esa barcha modellar;

Randomforest.pkl, XGBoost.pkl, BestModel.pkl
saqlanadigan joy.

Nega shu kalar qaytib kelmoqda

Bu eng muhim jafha.

Jababi ML biz martalik emas.


lasalan;

- Bugun 10000 ta data. Model accuracy 97%

- Biz oy o'tdi -> Gangi 5000 ta data keldi.
Eski model endi yaxshi ishlamayapti.

shunda

New data



Preprocessing



Training



Validation



New Best Model



Production

Yana boshidan
ishlaydi.

Bunga: Continuous
learning yoki Retraining
pipeline deyiladi.

Barcha strelkaning mantiqi

User



App data



Prediction Serving



Prediction



Prediction logging



Dataset grows



Data preprocessing



Train New Model → Best Model → Model storage

Prediction serving

App logging

Ordinal Encoder 'dagi
`unknown_value = -1` shu parametрни
 nega `-1` qiymat qabul qiladi, boshqa
 qiymatlar ham qabul qiladimi?

- Agar "ha" bolsa Nega?

- Agar "yo'q" bolsa Nega?

Ordinal Encoder → odatda kategoriyalarни
 alifbo tartibida kodlaydi, shu uchun ra-
 qamlar niz ketgandek bo'lasligi mumkin.

Muammo qachon paydo bo'ladi?

Test ma'lumotida yangi kategoriya hildi:
`Yellow` → Model bu `training` vaqtida
 hech qachon ko'rmaagan.

Agar siz: `OrdinalEncoder()` deb ishlatangiz,
 xato chiqadi: `Value Error : Found unknown categories`
`['Yellow']`

`handle_unknown = "use_encoded_value"` nima
 qiladi? → Bu parametr encodingga shunday
 deydi:

"Agar yangi kategoriya chiqsa, xato berma.
 Men bergan qiymatni ishlat"

Shuning uchun:

Ordinal Encoder (

handle_unknown = "use-encoded-value",

unknown_value = -1

)

Natija:

Blue $\rightarrow 0$

Green $\rightarrow 1$

Red $\rightarrow 2$

Yellow $\rightarrow -1$

Nega aynan -1? $\Rightarrow$ Aslida -1 majburiy emas. Ubi tanlash = asriy sababi: kodlangan haqiqiy kategoriyalar odatda:

0

1

2

3

4

... boladi

Shu = u-n: -1 ular = hech biri b/n to'qilash maydi. Model darrov tushunadi: "Bu oldin ko'rilgan kategoriya"

unknown_value = None boladimi? Yox. Sababi encoder chiqishi sonlardan iborat bo'lishi k-k.

unknown_value = "unknown" boladimi? Yox. Sababi

Ordinal Encoder sonli qiymat/ qaytaradi. String qaytara olmaydi.